

deep_v9 生成器质量、版本进步与真实窗口对比报告

基于冻结 correlation-cluster reference 的 1D diffusion 调参诊断

DSS x Mizuho HW01

2026 年 6 月 13 日

读者与保密说明。本报告供项目组及生成器调参队友使用，只包含 aggregate score distributions、feature-family summaries、block/bridge summaries 与冻结真实窗口 reference。报告不包含 raw rows、sample rows、原始 CSV 内容或逐行生成序列值。

结论先行

deep_v9 相比 deep_v8 有明确且覆盖全分布的进步，但仍未进入真实窗口分布带。 Median AvgD 从 1.136 降至 1.007, 改善 11.3%; P90 从 1.263 降至 1.118, 改善 11.5%; 标准差也从 0.096 降至 0.083。与此同时，真实窗口 median 仅为 0.613, v9 与真实窗口的 median gap 仍为 0.395, KS statistic 为 0.980, 验证状态仍是 distribution_separated_above_real_reference。下一轮 tuning 的首要矛盾已经更集中: **roughness/path texture、regime structure、block-level heterogeneity、volatility clustering 与 volatility burst dynamics**。v9 在边际分布、tails 和多尺度 block features 上明显优于 v8, 但 roughness、regime summary 与 burst dynamics 出现回退或仍与真实窗口相距较远。

1. 评估对象、配置与 score 含义

deep_v9 输入包含 2,048 对 sp500_i/dgs10_i two-asset candidates, 每对有 5,120 个生成时间步。与 deep_v8 完全相同，本次按 1,024-row diffusion-native blocks 构造 10,240 条 1,260×2 scoring paths, 并使用同一 feature builder、同一 548-feature cluster mapping 和同一冻结 reference stats。

核心指标 **average_cluster_robust_distance** 越低, 表示该 scoring path 的 correlation-cluster feature structure 越接近真实 rolling-window support。它是**诊断距离**，不是概率、不是训练标签，也不应作为 1D diffusion 的唯一 loss。模型调参应同时观察分布位置、右尾、family 结构和跨 block 稳定性。

Table 1: 真实窗口、deep_v8 与 deep_v9 的核心 score 对比

数据集	数量	Mean	Std.	P10	Median	P90
真实窗口	643	0.616	0.101	0.479	0.613	0.753
deep_v8	10,240	1.138	0.096	1.018	1.136	1.263
deep_v9	10,240	1.010	0.083	0.906	1.007	1.118

直接判断：v9 的进步不是只发生在少数 best samples。P10、median、P90 和 mean 都同步左移，且分布宽度收窄，因此可以认为 generator 的整体质量和稳定性均有实质改善。不过，v9 的大部分质量谱仍位于真实窗口右侧，尚不能表述为“已经接近真实分布”。

2. 三方分布对比：进步真实存在，分布分离仍然明显





Figure 1: 真实窗口、deep_v8 与 deep_v9 的 AvgD 密度。v9 相对 v8 明显左移，但仍位于真实窗口分布右侧。

图 1 显示 v9 与 v8 之间已有清晰间隔，说明本轮调整不是测量噪声级别的变化。另一方面，v9 与真实窗口仅在极低距离尾部有少量重叠：只有 0.059% 的 v9 paths 落在真实 P90 以下，5.36% 不超过真实窗口最大距离。作为对照，v8 对应比例分别为 0% 和 0.27%。这说明 v9 已经提高了“偶尔进入真实支持边界”的能力，但尚未形成稳定覆盖。

Quantile curve comparison

Improvement should appear across the full curve, especially the median and right tail, rather than only among a few selected paths




Frozen real reference: 643 rolling windows; each generated version: 10,240 resampled scoring paths.

Figure 2: 1%–99% 分位曲线。v9 在几乎整条曲线上优于 v8，但与真实窗口仍保持系统性间隔。

图 2 是比单一 median 更严格的判断。v9 曲线整体位于 v8 下方，说明改进覆盖中心区域和右尾；但三条曲线没有大范围交叠，冻结验证给出的 KS statistic 为 0.980，仍支持“分布分离”的结论。

Median and right-tail progress

deep_v9 improves median by 11.3% and P90 by 11.5% versus deep_v8, while a material gap to real windows remains.



Lower values indicate closer agreement with supported real-reference feature structure.

Figure 3: Median 与 P90 进步。v9 同时改善中心质量和差样本右尾，而不是只优化 top paths。

3. v8 到 v9：哪些行为改善，哪些发生回退

版本对比使用完全相同的 feature-level family metric，因此 delta 可以直接解释：负值表示 v9 距离下降，即改善；正值表示回退。




Figure 4: Feature-family median distance 的 v9-minus-v8 变化。蓝色负值为改善，琥珀色正值为回退。

Table 2: v8 到 v9 的主要 family 变化

Feature family	Median delta	P90 delta	解释
distribution_level	-0.306	-0.485	边际尺度和中心分布显著改善。
distribution_tail	-0.212	-0.243	tails 更接近参考结构。
block_21	-0.188	-0.372	短窗口局部特征明显改善。
block_level_heterogeneity	-0.150	-0.862	相对 v8 改善很大，但绝对真实差距仍高。
roughness_texture	+0.243	+0.290	明确回退，且成为当前最大真实差距。
regime_summary	+0.184	+0.262	regime duration/transition texture 回退。
volatility_burst_dynamics	+0.072	+0.164	burst onset、duration 或 recovery 仍需调整。

这里最重要的判断是：**v9 不是简单地全面变好，而是发生了质量结构迁移**。边际分布、tail 和多尺度 block summaries 改善，推动总 AvgD 左移；但 roughness、regime 和 burst 等动态 texture 变差。下一轮不能只继续压低 total score，否则可能进一步牺牲真实市场的时序质感。

4. v9 与真实窗口：当前 tuning 优先级

下面的真实比较采用冻结验证包中的 **cluster-family aggregation**。它与上一节的 feature-level version delta 粒度不同，因此用于判断“距离真实还差在哪里”，不把绝对数值与上一节直接相减。




Figure 5: deep_v9 相对真实窗口的 median cluster-distance gap。正值越大，当前诊断优先级越高。

Table 3: deep_v9 相对真实窗口的主要 cluster-family gap

Feature family	Median gap	P90 gap	调参含义
roughness_texture	2.195	4.552	首要问题；检查 sampler/noise schedule 与局部粗糙度尾部，避免异常锯齿或过强短频噪声。
regime_summary	1.052	1.800	calm/stress duration 与 transition frequency 不像真实窗口。
block_level_heterogeneity	1.015	4.188	不同局部窗口的结构差异过大或不稳定。
volatility_clustering	0.554	0.411	absolute/squared return persistence 仍不足或尺度错误。
volatility_burst_dynamics	0.552	0.475	高波动事件的进入、持续和恢复过程仍不真实。
path_texture	0.417	0.000	中心 texture 有偏差，但右尾并非当前最严重部分。

相对表现较好的 families 包括 cross-asset dependence、dynamic cross-asset dependence 与 autocorrelation，其 median gap 为负。这不表示这些机制已经“完美”，而表示在当前 cluster-family robust distance 下，它们不是下一轮的首要瓶颈。尤其不建议为了进一步优化总分而破坏目前已经相对合理的 cross-asset structure。

5. 重采样规则与风险：为什么 score 不能脱离构造过程解释

兼容原因。生成器的原生评估单位是 1,024 rows，而 discriminator 固定要求 $1,260 \text{ rows} \times 2 \text{ numeric return columns}$ 。本次保持与 v8 完全相同的确定性 bridge：每个 native block 补 236 rows。这样可以进行公平版本比较，但它仍是一种评估适配，不是 generator 原生输出。

具体构造

每个 5,120-row candidate 被拆成 5 个完整 1,024-row blocks。对于 blocks 0–3:

$$\text{scoring path}_k = \text{native block}_k \parallel \text{first 236 rows of native block}_{k+1}.$$

bridge direction 记为 next。对于最后的 block 4，因为不存在后续 block:

$$\text{scoring path}_4 = \text{native block}_4 \parallel \text{last 236 rows before native block}_4.$$

bridge direction 记为 previous。两资产顺序固定为 $\text{asset_1_return} = \text{sp500_i}$ 与 $\text{asset_2_return} = \text{dgs10_i}$ 。

主要风险

- **Boundary artifact:** 1,024 与 236 的连接处可能创造 generator 原生不存在的局部跳变，影响 roughness、burst、rolling volatility 和 short-window features。
- **Block/bridge confounding:** block 4 永远使用 previous bridge，因此无法仅凭两组 boxplot 把“最后 block 的位置效应”与“bridge direction 效应”完全分离。
- **Dependence leakage:** blocks 0–3 借用下一 block 的 236 rows，一条 scoring path 并不等于纯粹的单个 diffusion sample block。
- **Regime mixing:** 如果连接两侧位于不同 volatility regimes，拼接可能人为改变 regime duration、burst recovery 和 block heterogeneity。
- **Comparison validity:** v8/v9 只有在 feature mapping、reference stats、block size、bridge length 与 direction rule 全部固定时才能公平比较。本次满足这一要求。
- **Optimization leakage:** 若直接把 discriminator score 当唯一 loss，模型可能迎合当前 548 features，而没有提升更广义的金融真实性。

6. 当前 bridge 与 block 风险有多大

deep_v9 的 next-bridge mean AvgD 为 1.007，previous-bridge mean 为 1.021，差约 0.013；整体标准差为 0.083。该差异不够大到推翻本次结论，但比 v8 报告中的约 0.009 略高，需要继续监控。由于 previous 只对应 block 4，应将它解释为“可能存在轻度末端位置/ bridge 联合效应”，而不是已经证明 bridge 本身造成偏差。

Figure 5. Block sensitivity across 1024-native windows

Diagnostic distance across 10,240 scored paths from 2,048 candidate pairs and 5 native blocks; lower distance = more real-like. Block-level drift suggests generator regime or sampling texture differences.




Figure 6: deep_v9 的 block sensitivity。block 4 同时是唯一 previous-bridge group。

Figure 6. Bridge direction diagnostic

Compares deterministic next-block bridge versus previous-block bridge; large separation would indicate resampling artifact risk.




Figure 7: Bridge direction diagnostic。当前差异轻度存在，但与 block position 混杂。

7. 下一轮 tuning：建议按实验顺序推进

Table 4: deep_v10 建议实验顺序

优先级	目标	建议改动与诊断	成功判据
1	Roughness/path texture	检查 noise schedule、denoising strength、采样步数和短频噪声；比较 return increment roughness 与高分位局部变化。	roughness median/p90 明显下降，同时 distribution tail 不回退。
2	Regime structure	监控 calm/stress duration、transition count、21/63/252 窗口的 regime consistency；考虑更长上下文或显式 regime conditioning。	regime summary 与 block heterogeneity 同时改善。
3	Volatility dynamics	在训练与验证中加入 absolute/squared return ACF、burst onset/duration/recovery 的辅助诊断；避免只匹配 unconditional variance。	volatility clustering 和 burst family gap 下降，P90 不恶化。
4	保留已获得的改进	把 distribution level/tail 和 block 21/63/252 指标作为 guardrails，而非继续单独极限优化。	v10 不丢失 v9 的整体 11% 左移。
5	稳定性与重采样	固定 1,024+236 规则用于版本追踪；另加原生 1,024-only diagnostics，未来最好直接生成独立 1,260-row evaluation paths。	block 4 与其他 blocks 的差距缩小，结论对 bridge rule 更稳健。

推荐实验设计。每次只改变一类关键设置，并同时报告 median、P90、std、真实 P90 覆盖率、真实最大值覆盖率，以及上述五个重点 feature families。不要用少数 top candidates 替代全分布结果。若 total AvgD 下降但 roughness/regime 继续恶化，应判为“有条件进步”，而非无保留升级。

8. 最终判断与交付口径

1. **是否比 v8 好：**是。中心、右尾和方差均明显改善，且使用了相同配置。
2. **是否已经像真实窗口：**否。median gap 0.395、KS 0.980，绝大多数 paths 仍高于真实 P90。
3. **最值得保留的进步：**distribution level/tail、多尺度 block features 和整体稳定性。
4. **下一轮首要问题：**roughness、regime texture、block heterogeneity、volatility clustering 与 burst dynamics。
5. **重采样结论：**当前 bridge risk 轻度但非零，不是本次总体分离的主因；未来版本必须固定规则，并逐步引入原生长度验证。

本报告中的 score 应作为模型行为诊断和实验排序依据，不作为 leaderboard 证明，也不作为 diffusion 的唯一训练目标。真正的成功标准是：v10 在不破坏 cross-asset dependence 和 v9 边际分布改进的前提下，让全分布继续左移，并缩小 roughness/regime/volatility dynamics 的真实窗口差距。